

Predavanje 2 — Uvod u digitalnu obradu i analizu slike

Forenzička analiza digitalne slike

Damir Krstinić


FESB — Sveučilište u Splitu

1.

Kako vidimo

Svjetlost

- ▶ Svjetlost je **elektromagnetsko zračenje** koje podražuje fotoreceptore oka
- ▶ Ljudsko oko osjetljivo je na vrlo mali dio spektra: približno **380-750 nm**




Boja predmeta

- ▶ Izvor svjetla ima svoju **spektralnu raspodjelu energije** $L(\lambda)$
- ▶ Površina predmeta dio valnih duljina upija, a dio odbija: **reflektivnost** $\rho(\lambda)$
- ▶ U oko (ili kameru) stiže:


$$I(\lambda) = \rho(\lambda) L(\lambda)$$

- ▶ Boja koju vidimo ovisi i o predmetu **i o izvoru svjetla**
 - ▶ isti predmet pod žaruljom i pod dnevnim svjetlom daje drukčiji $I(\lambda)$
 - ▶ mozak to kompenzira; kamera mora to učiniti računski — **balans bijele**

Ljudski vizualni sustav



- ▶ **Optički sustav** (rožnica, leća) fokusira sliku na mrežnicu
- ▶ **Mrežnica** pretvara svjetlost u električne signale
- ▶ **Mozak** te signale tumači



Štapići i čunjići

Čunjići — fotopski (svijetli) vid


- ▶ 6–7 milijuna, uglavnom u žutoj pjegi
- ▶ osjetljivi na boju — tri vrste
- ▶ svaki povezan na vlastiti živac → oštra, detaljna slika

Štapići — skotopski (tamni) vid

- ▶ 75–150 milijuna, raspršeni po mrežnici
- ▶ znatno osjetljiviji, ali **ne razlikuju boje**
- ▶ više štapića dijeli jedan živac → manje detalja


Pri slabom svjetlu vidimo štapićima — zato u mraku ne raspoznavamo boje.

Odziv fotoreceptora




- ▶ Tri vrste čunjića s maksimumom odziva oko **420, 534 i 564 nm**
- ▶ Odzivi se jako preklapaju
- ▶ Štapići (isprekidano): maksimum oko **498 nm**
- ▶ Model odziva triju vrsta čunjića naziva se **LMS**

Metamerizam



Oko ne može rekonstruirati spektar: svjetlost svodi na **tri broja**. Fizički različita svjetlost može dati istu boju.

Metamerizam – primjer zaslona



- ▶ Zaslon **ne emitira** žutu valnu duljinu — samo crvenu i zelenu
- ▶ Odziv čunjića je isti, pa vidimo žutu


Različiti spektri mogu dati istu boju — zato su za zapis i prikaz boje dovoljne tri vrijednosti po pikselu.

2.

Osnove boje


Miješanje boja

- ▶ **Trikromatska teorija:** gotovo svaka boja može se dobiti miješanjem tri primarne boje



- ▶ **Aditivno** — svjetla se zbrajaju (zasloni, projektori): RGB
- ▶ **Suptraktivno** — pigmenti upijaju svjetlost (tisak): CMY + crna (K)

RGB prostor boja



- ▶ Svaka boja je točka u kocki (R, G, B)
- ▶ Crna je u ishodištu $(0, 0, 0)$, bijela u suprotnom vrhu $(1, 1, 1)$ — na slici središnji vrh
- ▶ Dijagonala $R = G = B$ su **sive razine**
- ▶ Uz 8 bita po kanalu: $256^3 \approx 16,7$ milijuna boja






Iz boje u sive razine









$$I = 0,299 R + 0,587 G + 0,114 B$$

- ▶ Jednostavni prosjek daje istu sivu za crvenu, zelenu i plavu
- ▶ Težine prate osjetljivost oka — najveću na zeleno (ITU-R BT.601, `cv2.cvtColor`)

Koja boja ima najviše crvene, zelene ili plave?




Koja boja ima najviše crvene, zelene ili plave?



Kako „mislino“ boje?

Opažanje boje opisujemo tonom, zasićenjem i svjetlinom:


1. Ton (Hue) — dominantna valna duljina



2. Zasićenje (Saturation) — udio čiste boje, odmak od sive




3. Vrijednost (Value) — svjetlina, intenzitet




Čovjek ne može rastaviti boju na komponente R, G i B, niti odrediti valnu duljinu. Intuitivan opis boje daju prostori HSV, HSI i HLS.

HSV prostor boja



- ▶ **H** (ton) — kut na kružnici boja, $0-360^\circ$
 - ▶ OpenCV ga zapisuje kao $0-179$, da stane u `uint8`
- ▶ **S** (zasićenje) — udaljenost od osi sivih razina, $0-1$
- ▶ **V** (vrijednost) — položaj na osi sivih: dno je crna, vrh bijela
- ▶ Pretvorba iz RGB je nelinearna

HSV prostor boja — primjer




- ▶ Kada je $S \approx 0$, **ton nije definiran** — kanal H je šum (bijela kaciga, siva pozadina)

3.


Od svjetla do piksela

Senzor i CFA filtar




- ▶ Fotosenzor mjeri samo **količinu svjetla**, ne i boju
- ▶ Ispred senzora je mozaik filtara boja — **CFA** (*Color Filter Array*)
 - ▶ svaki piksel „vidi” samo jednu komponentu
- ▶ **Bayerov uzorak** (Kodak, patent 1976.):
 - ▶ 50 % zelenih, 25 % crvenih, 25 % plavih
 - ▶ zelenih je dvostruko jer oko najviše detalja vidi upravo preko zelene komponente

Demozaikiranje




- ▶ U svakom pikselu **dvije od tri** vrijednosti boje interpoliraju se iz susjeda
- ▶ Na finim detaljima nastaju artefakti — lažne boje
- ▶ Interpolacija ostavlja **pravilnu korelaciju među susjednim pikselima**, specifičnu za algoritam proizvođača — važan forenzički trag

Obrada u kameri




- ▶ Tipični koraci: demozaikiranje → balans bijele → korekcija boja → **gama korekcija** → uklanjanje šuma, izoštravanje → kompresija
- ▶ Svaki proizvođač ove korake provodi na svoj način — rezultat nosi **potpis uređaja**

Gama korekcija



- ▶ Kodiranje u kameri: $V_c = V_{in}^{1/\gamma}$, prikaz: $V_{out} = V_c^\gamma$, tipično $\gamma \approx 2,2$
- ▶ Izvorno kompenzira nelinearnost CRT zaslona
- ▶ Danas važnije: oko je osjetljivije na razlike u **tamnim** tonovima
 - ▶ gama kodiranje tamnim tonovima daje više od 256 raspoloživih razina



RAW i obrađena slika

RAW

- ▶ Izravno očitavanje senzora nakon A/D pretvorbe
- ▶ Jedna vrijednost po pikselu (mozaik)
- ▶ 12-14 bita, linearni odziv, bez obrade
- ▶ Format proizvođača (CR3, NEF, ARW...) ili otvoreni DNG

Obrađena slika

- ▶ Tri kanala po pikselu (RGB)
- ▶ 8 bita po kanalu
- ▶ Demozaikirana, balansirana, gama kodirana
- ▶ Najčešće sažeta (JPEG, HEIF)

RAW je najbliži onome što je senzor zabilježio, ali ni RAW datoteka sama po sebi ne jamči autentičnost.

4.

Zapis digitalne slike


Uzorkovanje i kvantizacija



- ▶ **Uzorkovanje** — kontinuirana scena mjeri se u konačnom broju točaka (piksela)
- ▶ **Kvantizacija** — izmjerena vrijednost zaokružuje se na jednu od konačnog broja razina

Nyquist-Shannonov teorem

Ako se signal uzorkuje frekvencijom barem **dvostruko većom** od njegove najviše frekvencije, može se točno rekonstruirati iz uzoraka.



- ▶ Prerijetko uzorkovan brzi signal daje iste uzorke kao spori — **aliasing**
- ▶ U slici je frekvencija uzorkovanja gustoća piksela: detalj finiji od dva piksela pojavljuje se kao lažni, grublji uzorak

Aliasing u slici i antialiasing



izvorna slika



smanjeno bez antialiasinga



uvećani detalj

- ▶ Cigle na tornju finije su od razmaka piksela smanjene slike → lažni valoviti uzorci (**moiré**)
- ▶ **Antialiasing:** niskopropusno filtriranje *prije* uzorkovanja (u kameri optički filter ispred senzora)
- ▶ I lažne boje kod demozaikiranja su aliasing — R i B uzorkovani su samo u svakom drugom pikselu

Slika kao matrica




$f(m, n)$ — vrijednosti piksela

199	192	182	174	154	157	149	139	129	125
192	184	176	161	150	146	132	123	123	116
181	169	162	150	145	137	123	117	111	111
170	162	155	141	134	124	114	110	104	109
156	146	141	128	119	111	110	102	97	94
136	126	120	110	105	100	95	93	89	94
112	111	101	95	89	89	87	90	97	105
91	88	87	85	86	89	96	103	110	111
78	81	84	87	92	104	110	112	114	112
82	86	92	101	108	112	116	116	118	117

- Slika sivih razina je matrica $f(m, n)$: m je redak, n stupac, ishodište gore lijevo

Slika u boji



```
img = cv2.imread("slika.jpg")  
print(img.shape, img.dtype)  
B, G, R = cv2.split(img)
```

POZOR: OpenCV čita kanale redom B, G, R
(400, 600, 3) uint8

► **Binarna slika** — samo vrijednosti 0 i 1 (maske, segmentacija)

Prostorna rezolucija i dubina boje

320 × 320



8 bit (256 razina)

80 × 80



4 bit (16 razina)

40 × 40



2 bit (4 razine)

20 × 20



1 bit (2 razine)




Cjelobrojni zapis — uint8

- ▶ Najčešći zapis: 8 bita po kanalu, vrijednosti **0-255**
- ▶ Što kada rezultat operacije izađe iz tog raspona?

```
a = np.full((2, 2), 200, np.uint8)
b = np.full((2, 2), 100, np.uint8)
a + b                # 44    -> preljev (modulo 256)
cv2.add(a, b)        # 255   -> zasićenje (odsijecanje)
b - a                # 156
cv2.subtract(b, a)   # 0
```

Ista operacija daje različit rezultat ovisno o biblioteci — bez ikakve poruke o pogrešci.

Zašto pomični zarez?




- ▶ Međurezultati se računaju u pomičnom zarezu, najčešće u rasponu $[0, 1]$
- ▶ U uint8 se zaokružuje **samo jednom, na kraju** — svako zaokruživanje trajno gubi informaciju

Interpolacija

Najbliži susjed (*nearest neighbor*)

- ▶ Novi piksel preuzima vrijednost najbližeg izvornog piksela
- ▶ Uvećanje = ponavljanje redaka i stupaca
- ▶ Ne stvara nove vrijednosti — samo ponavlja postojeće



Interpolacija


Bilinearna interpolacija

- ▶ Linearno, prvo po retcima, zatim po stupcima

A	B	→	A	e	B
			f	g	h
C	D		C	i	D

$$e = \frac{A+B}{2}, \quad i = \frac{C+D}{2}$$


$$g = \frac{e+i}{2} = \frac{A+B+C+D}{4}$$



Interpolacija

Bikubična interpolacija

- ▶ Uzima u obzir veći broj susjednih piksela: kubni polinom kroz $4 \times 4 = 16$ susjeda
- ▶ Oštrij rubovi od bilinearne interpolacije




Interpolacija

Lanczos (sinc) interpolacija

$$S(x) = \sum_{i=\lfloor x \rfloor - a + 1}^{\lfloor x \rfloor + a} s_i L(x - i)$$

- ▶ $L(x) = \text{sinc}(x) \text{sinc}(x/a)$
za $|x| < a$
- ▶ 2D: $L(x, y) = L(x) L(y)$
- ▶ Približava idealnu rekonstrukciju iz Nyquist-Shannonova teorema



Područje interesa (ROI)

- Često analiziramo samo dio slike — **ROI** (*Region of Interest*)

```
roi = img[120:150, 100:180]      # retci 120-149, stupci 100-179
print(ro.shape)                  # (30, 80, 3)

roi[:] = 0                       # POZOR: mijenja i izvornu sliku!
roi = img[120:150, 100:180].copy() # neovisna kopija
```

U forenzičkoj analizi izvorna slika se nikada ne mijenja — radi se isključivo na kopiji.

5.

Osnovne operacije

Vrste operacija na slici

- ▶ **Točkaste** — izlaz ovisi samo o pikselu na istoj koordinati

$$g(m, n) = T(f(m, n))$$

- ▶ **Lokalne** — izlaz ovisi o pikselu i njegovom **susjedstvu** (filtiri, konvolucija)
- ▶ **Globalne** — izlaz ovisi o **svim** pikselima slike (histogram, Fourierova transformacija)

Točkaste operacije

izvornik




negativ: $255 - f$



prag: $f > 120$



slučajna LUT



- ▶ **LUT** (*lookup table*) — tablica izlaznih vrijednosti za svih 256 mogućih ulaza
 - ▶ preslikavanje je obično indeksiranje: $g = \text{lut}[f]$
 - ▶ bilo koja točkasta operacija na uint8 slici može se zapisati kao LUT

Razlika dviju slika

slika A



slika B



$|A - B|$ (pojačano)



- ▶ Izmjenu koju oko ne primjećuje razlika odmah otkriva
- ▶ Uvjet: slike moraju biti **poravnate** i jednako zapisane — inače razlika pokazuje sve, a ne samo izmjenu

Geometrijske operacije

- ▶ Izrezivanje, skaliranje, rotacija, perspektivne transformacije
- ▶ Novi pikseli ne padaju na mrežu izvornih → vrijednosti se **interpoliraju**
 - ▶ najbliži susjed, bilinearna, bikubična interpolacija



`mala = cv2.resize(img, None, fx=0.5, fy=0.5, interpolation=cv2.INTER_AREA)`

Interpolacija uvodi periodične korelacije među pikselima — trag koji otkriva da je dio slike skaliran ili rotiran.

6.

Histogram


Histogram i kumulativni histogram



$$h(k) = |\{(m, n) : f(m, n) = k\}|, \quad H(k) = \sum_{i=0}^k h(i)$$


```
h = np.bincount(g.ravel(), minlength=256)    # ili cv2.calcHist
```

Histogram slike u boji




- ▶ Za sliku u boji računaju se tri nezavisna histograma, za svaki kanal posebno
- ▶ Višedimenzionalni histogram opisuje zajedničku raspodjelu kanala

Histogram ne vidi prostor




Histogram opisuje samo **koliko** je kojih vrijednosti, a ne **gdje** su u slici.

Histogram ne vidi prostor — primjer



- Iste šibice, različito razmještene — histogrami su gotovo jednaki

Čitanje histograma



- **Odsijecanje:** svi pikseli izvan raspona svedeni su na 0 ili 255 — ta informacija je nepovratno izgubljena

7.

Poboljšanje slike

Rastezanje histograma

- ▶ Raspon vrijednosti $[f_{min}, f_{max}]$ preslikava se na cijeli raspon $[0, 255]$:

$$g = \frac{f - f_{min}}{f_{max} - f_{min}} \cdot 255$$

- ▶ Nekoliko krajnjih piksela može onemogućiti rastezanje
 - ▶ zato se često odbacuje mali postotak najtamnijih i najsvjetlijih (npr. 0,5 %)
- ▶ Često je ugrađeno u automatiku uređaja za prikaz

Ujednačavanje histograma

- ▶ Cilj: histogram u kojem su sve razine približno jednako zastupljene
- ▶ Funkcija preslikavanja je **normalizirani kumulativni histogram**:


$$g(m, n) = 255 \cdot \frac{H(f(m, n))}{M \cdot N}$$

- ▶ Postupak:
 1. izračunati kumulativni histogram $H(k)$
 2. normalizirati ga na najveću vrijednost (255)
 3. koristiti ga kao LUT


`eq = cv2.equalizeHist(g)`

Rastezanje i ujednačavanje




izvornik




rastezanje



ujednačavanje



Lokalno ujednačavanje histograma



izvornik




globalno ujednačavanje



lokalno ujednačavanje

- Histogram se ujednačava zasebno u manjim područjima slike — ističu se lokalni detalji (npr. CLAHE)

Logaritamsko i eksponencijalno preslikavanje



izvornik



log: tamni detalji




exp: svijetli detalji



- ▶ **Logaritamsko** preslikavanje razvlači tamne tonove — ističe detalje u sjenama
- ▶ **Eksponencijalno** preslikavanje razvlači svijetle tonove

Poboljšanje ostavlja trag




- ▶ 8-bitna slika ima samo 256 mogućih vrijednosti
- ▶ Rastezanjem se one razmiču — između njih ostaju **prazni stupci**
- ▶ Pravilan uzorak rupa i šiljaka („češalj“) otkriva da je kontrast mijenjan, čak i kada slika okom izgleda prirodno

8.

Konvolucija i korelacija

Klizni prozor



- Prozor (jezgra) klizi preko slike; izlaz je **težinska suma** piksela ispod prozora

$$g(m, n) = \sum_j \sum_k h(j, k) f(m - j, n - k)$$

Konvolucija i korelacija

- ▶ **Konvolucija** — jezgra se prije množenja rotira za 180°
- ▶ **Korelacija** — ista operacija bez rotacije:

$$g(m, n) = \sum_j \sum_k h(j, k) f(m + j, n + k)$$

- ▶ Za simetrične jezgre rezultat je isti
- ▶ Na rubovima nedostaju pikseli → **dopunjavanje** (nule, rub, zrcaljenje)

```
k = np.array([[1, 2, 1], [2, 4, 2], [1, 2, 1]], np.float32) / 16  
g = cv2.filter2D(img, -1, k, borderType=cv2.BORDER_REFLECT)
```

cv2.filter2D računa korelaciju — nesimetričnu jezgru treba prethodno rotirati.

Korelacija kao mjera sličnosti


slika



uzorak



normalizirana korelacija



- ▶ **Normalizirana korelacija** mjeri koliko je dio slike sličan zadanom uzorku
- ▶ Najveća vrijednost pokazuje gdje se uzorak nalazi
- ▶ Isti princip koristi se za otkrivanje **kloniranih** dijelova slike (copy-move)

Primjeri filtara

slika sa šumom



prosjek 5×5



Gaussov filter



izvornik



izoštavanje (Laplace)



rubovi (Sobel)



Statistički nelinearni filtri

- ▶ **Filtri poretka** (*order-statistic filters*): izlazna vrijednost ovisi o **redoslijedu** vrijednosti piksela u prozoru
 - ▶ **medijan** — srednja po redu vrijednost
 - ▶ **max** — najveća vrijednost
 - ▶ **min** — najmanja vrijednost
- ▶ Nisu linearni: ne mogu se zapisati kao težinska suma, dakle ni kao konvolucija

Medijan filtar

- Pikseli unutar prozora sortiraju se po veličini, a izlaz je **srednja** vrijednost po redu

123	112	131
118	243	129
121	230	117

→

123	112	131
118	123	129
121	230	117

sortirano: 112 117 118 121 **123** 129 131 230 243

Medijan filtar dobro uklanja točkasti šum (*salt & pepper*) i pritom čuva rubove regija.

Medijan i usrednjavanje



ulazna slika



usrednjavanje 3×3



Gaussov filtar 3×3



medijan 3×3




75 % šuma (s&p)



usrednjavanje 9×9



Gaussov filtar 9×9



medijan 9×9

Konvolucija u forenzici



- ▶ Zaglađivanjem se procjenjuje „čisti” sadržaj slike
- ▶ Oduzimanjem ostaje **rezidual**: šum i fini detalji
- ▶ U šumu se krije **otisak senzora** — jedinstven za svaki fotoaparat

9. **Zaključak**

Ključno za forenziku

- ▶ Svaki korak nastanka i obrade slike ostavlja trag:
 - ▶ **demozaikiranje** — korelacija susjednih piksela
 - ▶ **obrada u kameri** — potpis proizvođača
 - ▶ **promjena kontrasta** — „češalj” u histogramu
 - ▶ **skaliranje i rotacija** — tragovi interpolacije
 - ▶ **šum senzora** — otisak uređaja
- ▶ **Sljedeće predavanje (P3):** matematički model slike i digitalni formati — prostori boja, zapis slike, JPEG, JFIF i EXIF